

Product & Technical Plan

Real-Time Vietnamese-English Business Meeting Translator

Challenge: AI Singapore Hackathon

Thời gian phát triển: 2 ngày

Định hướng: Product-first, ổn định, dễ vận hành, dễ bảo trì, có đường nâng cấp thành sản phẩm thực tế

Ngôn ngữ: Vietnamese ↔ English

Bối cảnh sử dụng: Cuộc họp trực tiếp giữa đoàn Việt Nam và Singapore

1. Executive Summary

Mục tiêu của đội không nên là xây dựng một hệ thống dịch thuật “ấn tượng về mặt AI” nhưng khó sử dụng. Mục tiêu nên là:

Xây dựng một sản phẩm phiên dịch cuộc họp có thể chạy ổn định trong buổi demo, phản hồi nhanh, giữ đúng ý nghĩa kinh doanh, dễ hiểu và không làm gián đoạn cuộc hội thoại.

Giải pháp được đề xuất là một **pipeline dạng cascade có kiểm soát**:

```
Microphone
  ↓
Audio preprocessing
  ↓
Voice Activity Detection
  ↓
Turn segmentation
  ↓
Streaming Speech-to-Text
  ↓
Text stabilization
  ↓
Business-aware Translation
  ↓
Post-processing
  ↓
Bilingual meeting interface
  ↓
Optional Text-to-Speech
```

Kiến trúc cascade được ưu tiên cho phiên bản hackathon vì:

- Dễ debug từng thành phần.
- Dễ thay thế model.

- Có thể hiển thị cả transcript gốc và bản dịch.
- Có thể đo latency riêng ở từng bước.
- Có fallback nếu một model gặp lỗi.
- Phù hợp hơn với định hướng maintainability và productization.

Một model end-to-end như SeamlessM4T hoặc SeamlessStreaming vẫn nên được chuẩn bị như một nhánh thử nghiệm hoặc fallback. SeamlessM4T hỗ trợ ASR, speech-to-text translation, text-to-text translation và speech-to-speech translation; SeamlessStreaming được thiết kế cho dịch đồng thời với latency khoảng vài giây.

Tuy nhiên, giải pháp hackathon chính nên ưu tiên:

VAD + faster-whisper + Translation Model/API + Web UI

Đây là lựa chọn có xác suất hoàn thành và demo ổn định cao nhất trong hai ngày.

2. Product Vision

2.1 Tầm nhìn

Sản phẩm là một “meeting translation assistant” thay vì chỉ là một speech translation demo.

Sản phẩm phải giúp hai bên:

- Hiểu chính xác nội dung đối phương.
- Không phải thao tác nhiều.
- Không phải đợi quá lâu sau mỗi lượt nói.
- Có thể kiểm tra lại nội dung gốc.
- Nhận biết được ai đang nói và nói bằng ngôn ngữ nào.
- Theo dõi lại lịch sử cuộc họp.
- Sửa nhanh những lỗi liên quan đến tên riêng, thuật ngữ và con số.

2.2 Product promise

Speak naturally. See the original message and translation almost immediately.

2.3 Người dùng chính

Người nói tiếng Việt

- Nói tiếng Việt tự nhiên.
- Nhìn thấy transcript tiếng Việt.
- Người Singapore nhìn thấy bản dịch tiếng Anh.

Người nói tiếng Anh

- Nói tiếng Anh tự nhiên.

- Nhìn thấy transcript tiếng Anh.
- Người Việt nhìn thấy bản dịch tiếng Việt.

Người điều phối cuộc họp

- Bắt đầu hoặc dừng phiên dịch.
 - Chọn microphone.
 - Quan sát tình trạng hệ thống.
 - Sửa thuật ngữ hoặc transcript khi cần.
 - Chuyển chế độ nói nếu nhận diện ngôn ngữ tự động sai.
-

3. Product Principles

3.1 Stability over novelty

Không sử dụng một kiến trúc mới chỉ vì nó “cool” nếu chưa kiểm thử đủ.

Một pipeline đơn giản nhưng chạy ổn định sẽ có giá trị cao hơn một pipeline end-to-end phức tạp nhưng:

- Không biết lỗi nằm ở đâu.
- Khó tối ưu latency.
- Khó xử lý lỗi tên riêng.
- Không có fallback.
- Dễ crash khi demo.

3.2 Text-first, voice optional

Output chính nên là văn bản song ngữ.

Lý do:

- Dễ demo.
- Ít latency hơn speech-to-speech.
- Người dùng kiểm tra được bản gốc.
- Không gây tiếng vọng vào microphone.
- Không làm gián đoạn người đang nói.
- Không cần giải quyết voice cloning, giọng nói và TTS overlap.

TTS nên là tính năng tùy chọn, có nút bật hoặc phát lại từng câu.

3.3 Human-correctable

Không nên thiết kế hệ thống như một “black box”.

Người dùng cần có khả năng:

- Sửa transcript.

- Sửa tên người hoặc tên công ty.
- Thêm thuật ngữ vào glossary.
- Dịch lại một câu.
- Phát lại đoạn audio ngắn.
- Đánh dấu câu dịch chưa chính xác.

3.4 Graceful degradation

Khi một thành phần gặp vấn đề, hệ thống vẫn phải tiếp tục phục vụ ở mức tối thiểu.

Ví dụ:

- Translation model lỗi → vẫn hiển thị transcript gốc.
- TTS lỗi → vẫn hiển thị text.
- Auto language detection lỗi → cho phép chọn ngôn ngữ thủ công.
- Internet mất → chuyển sang model local.
- GPU quá tải → chuyển sang model nhỏ hơn hoặc tăng chunk size.
- Diarization lỗi → dùng Speaker A/Speaker B hoặc bỏ speaker label.

4. Success Metrics

4.1 Các chỉ số quan trọng cho hackathon

Nhóm	Chỉ số mục tiêu
First partial transcript	Dưới 1 giây
Stable transcript	1–2 giây sau khi người nói tạm dừng
Translation xuất hiện	0.5–1.5 giây sau transcript ổn định
Tổng perceived latency	Khoảng 2–3 giây
Crash trong demo	0
Mất câu hoàn toàn	Dưới 2% lượt nói
Sai ngôn ngữ	Dưới 5% lượt nói
Sửa đổi transcript liên tục	Hạn chế tối đa
Thao tác để bắt đầu	Tối đa 1–2 click

4.2 Các chỉ số chất lượng dịch

Đặc biệt đo độ chính xác đối với:

- Tên người.
- Tên công ty.
- Tên sản phẩm.
- Con số.

- Ngày tháng.
- Đơn vị tiền tệ.
- Tỷ lệ phần trăm.
- Điều khoản thương mại.
- Câu phủ định.
- Mức độ cam kết.
- Deadline.
- Hành động tiếp theo.

Ví dụ, dịch sai:

"We cannot deliver before Friday."

thành:

"Chúng tôi có thể giao trước thứ Sáu."

là lỗi nghiêm trọng hơn nhiều so với lỗi ngữ pháp nhỏ.

5. Recommended Product Scope

5.1 Must-have cho phiên bản hackathon

1. Thu âm trực tiếp từ microphone.
2. Voice Activity Detection.
3. Nhận diện tiếng Việt và tiếng Anh.
4. Speech-to-text gần thời gian thực.
5. Dịch Việt-Anh và Anh-Việt.
6. Hiển thị transcript gốc và bản dịch.
7. Phân biệt lượt nói.
8. Lịch sử hội thoại.
9. Nút bắt đầu, tạm dừng và kết thúc.
10. Trạng thái hệ thống rõ ràng.
11. Glossary cho tên riêng và thuật ngữ.
12. Chế độ chọn ngôn ngữ thủ công.
13. Local fallback hoặc ít nhất transcript local.
14. Logging latency và lỗi.

5.2 Should-have

- Tự động nhận diện hướng dịch.
- Speaker A/Speaker B.
- Chỉnh sửa transcript.
- Dịch lại câu.
- Export transcript Markdown hoặc JSON.
- Noise suppression.

- Chế độ full-screen.
- Cảnh báo microphone quá nhỏ hoặc quá lớn.
- Confidence indicator đơn giản.
- Nút “hold to talk” làm fallback.

5.3 Nice-to-have

- Text-to-speech.
- Speaker diarization đầy đủ.
- Meeting summary.
- Action items.
- Semantic correction bằng LLM.
- Tự học glossary trong cuộc họp.
- Kết nối Zoom, Teams hoặc Google Meet.
- Mobile client.
- Edge deployment hoàn toàn.

5.4 Không nên làm trong hai ngày

- Voice cloning.
- Đồng bộ môi chính xác.
- Fine-tune model lớn từ đầu.
- Full multi-speaker diarization phức tạp.
- Một kiến trúc microservice quá lớn.
- Kubernetes.
- Native mobile app nếu chưa có sẵn codebase.
- Hỗ trợ quá nhiều ngôn ngữ ngay trong demo.
- Một hệ thống tài khoản, thanh toán hoặc phân quyền hoàn chỉnh.
- RAG phức tạp trên tài liệu doanh nghiệp.

6. Proposed User Experience

6.1 Giao diện chính

Nên sử dụng giao diện hai cột hoặc hai vùng màu rõ ràng.

Meeting Translator		• Listening
Microphone: USB Conference Mic		Mode: Auto VI ↔ EN
ORIGINAL	TRANSLATION	
[Speaker A - VI] Chúng tôi dự kiến giao hàng vào ngày 25...	[English] We expect to deliver the shipment on the 25th...	
[Speaker B - EN] Could you confirm the	[Vietnamese] Anh/chị có thể xác nhận	

payment terms?	điều khoản thanh toán không?
[Pause] [Push to Talk] [Correct] [End Meeting]	

6.2 Trạng thái transcript

Nên phân biệt:

- **Listening** : đang nghe.
- **Transcribing** : đang nhận diện.
- **Partial** : transcript tạm thời.
- **Final** : transcript đã ổn định.
- **Translating** : đang dịch.
- **Completed** : hoàn tất.
- **Low confidence** : cần kiểm tra.
- **Error** : lỗi thành phần.

Transcript tạm thời nên hiển thị mờ hoặc italic.

Transcript final nên hiển thị rõ và không tiếp tục thay đổi, trừ khi người dùng chủ động sửa.

6.3 Turn-taking

Không nên dịch từng frame hoặc từng từ.

Thay vào đó:

- Hiển thị partial transcript liên tục.
- Chỉ gửi sang translation khi phát hiện một semantic segment tương đối hoàn chỉnh.
- Commit câu khi có:
- Dấu câu hợp lý.
- Khoảng im lặng.
- Độ dài tối đa.
- Speaker change.
- Người dùng bấm nút kết thúc lượt nói.

6.4 Manual fallback

Luôn có nút:

Hold to Speak Vietnamese
Hold to Speak English

Trong trường hợp auto language detection hoặc turn detection không ổn định, đội có thể sử dụng chế độ này trong demo mà sản phẩm vẫn trông hợp lý.

7. Architecture Options

7.1 Option A — Cascaded Pipeline

```
Audio
→ VAD
→ ASR
→ Text normalization
→ Machine translation
→ UI
→ Optional TTS
```

Ưu điểm

- Dễ debug.
- Dễ benchmark.
- Dễ thay model.
- Hiển thị được transcript gốc.
- Dễ xây glossary.
- Dễ thêm correction layer.
- Dễ fallback.
- Phù hợp product architecture.
- Có thể dùng local ASR và cloud translation.
- Có thể chuyển dần sang full on-premise.

Nhược điểm

- Latency cộng dồn.
- Lỗi ASR truyền sang translation.
- Cần quản lý partial/final transcript.
- Cần đồng bộ nhiều stage.

Kết luận

Đây là lựa chọn chính được khuyến nghị.

7.2 Option B — Direct Speech-to-Text Translation

```
Audio
→ Direct S2TT model
→ Translated text
```

Có thể thử SeamlessM4T hoặc SeamlessStreaming. Meta mô tả SeamlessM4T là mô hình đa phương thức hỗ trợ nhiều tác vụ, còn SeamlessStreaming tập trung vào simultaneous speech translation với latency thấp.

Ưu điểm

- Pipeline ngắn.
- Có khả năng giảm latency.
- Có tính nghiên cứu.
- Có bonus open-model và on-premise.

Nhược điểm

- Khó quan sát transcript trung gian.
- Khó sửa lỗi ASR.
- Khó áp glossary.
- Có thể yêu cầu GPU mạnh.
- Khó kiểm soát output.
- Khó xử lý riêng tên riêng, số và thuật ngữ.
- Tích hợp streaming có thể tốn nhiều thời gian.

Kết luận

Nên xây dưới dạng:

- Experimental backend.
- Benchmark candidate.
- Backup demo nếu kết quả tốt.

Không nên đặt toàn bộ khả năng demo vào hướng này nếu đội chưa có kinh nghiệm với model.

7.3 Option C — Cloud-first

Audio

- Cloud Streaming ASR
- Cloud Translation/LLM
- UI

Ưu điểm

- Chất lượng thường ổn định.
- Tốc độ triển khai nhanh.
- Ít phụ thuộc GPU.
- API streaming tốt.

Nhược điểm

- Phụ thuộc mạng.
- Chi phí.
- Không có bonus on-premise.
- Dữ liệu cuộc họp rời khỏi thiết bị.
- Có rủi ro API quota hoặc rate limit.

Kết luận

Có thể dùng làm **quality fallback**, không nên là con đường duy nhất.

7.4 Option D — Hybrid

```
Local audio processing
→ Local VAD
→ Local ASR
→ Local or cloud translation
→ Local UI
```

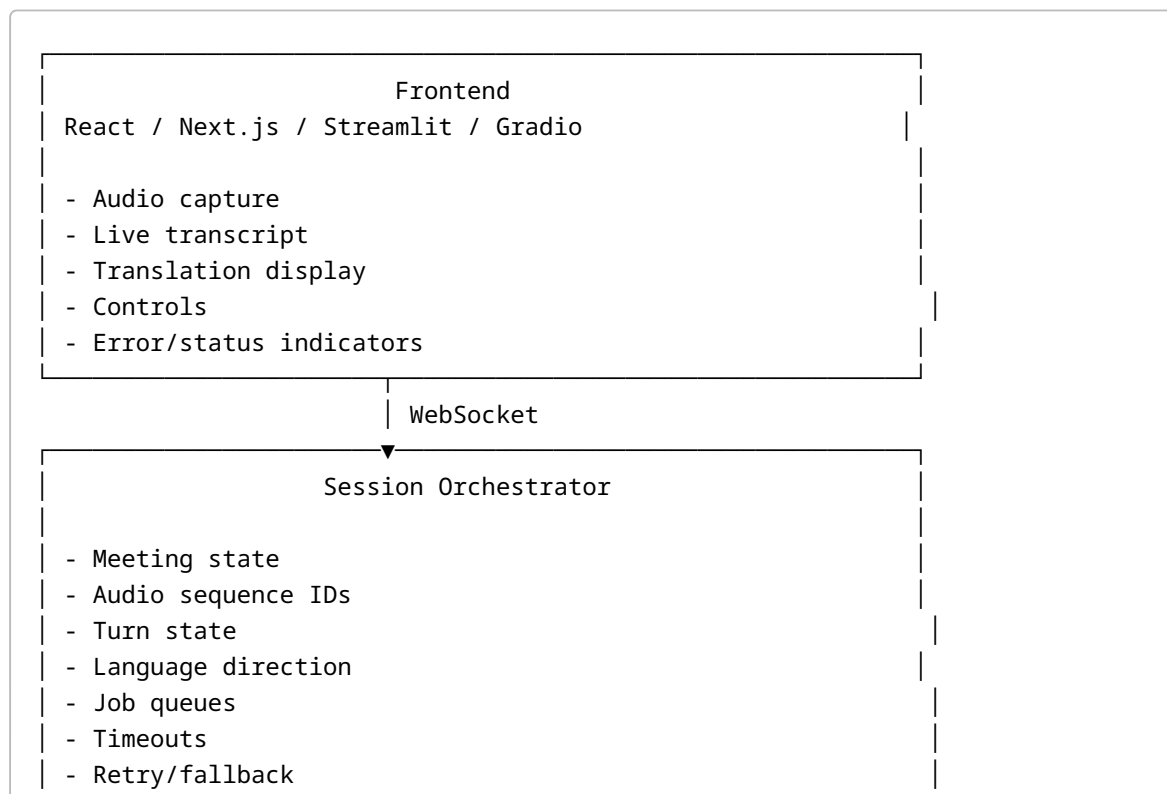
Ưu điểm


- Transcript vẫn chạy nếu mất mạng.
- Giảm lượng dữ liệu gửi ra ngoài.
- Có đường chuyển sang on-premise.
- Dễ đạt cân bằng chất lượng và tốc độ.

Kết luận

Đây là kiến trúc product phù hợp nhất.

8. Recommended System Architecture





9. Detailed Real-Time Pipeline

9.1 Audio Capture

Input

- Mono audio.
- 16 kHz hoặc 48 kHz.
- PCM 16-bit.
- Chunk 20–100 ms.

Khuyến nghị

Frontend gửi chunk qua WebSocket.

Mỗi chunk có metadata:

```
{
  "session_id": "meeting-001",
  "sequence": 124,
  "timestamp_ms": 17342,
  "sample_rate": 16000,
  "channels": 1
}
```

Product requirements

- Hiển thị input level.
- Cảnh báo mic muted.
- Cảnh báo clipping.
- Cho phép chọn microphone.
- Cho phép test mic trước cuộc họp.
- Không tự động đổi microphone giữa phiên.

9.2 Audio Preprocessing

Pipeline:

```
Raw audio
→ Channel conversion
→ Resampling
→ High-pass filter
→ Noise suppression
→ Automatic gain control, optional
→ VAD
```

Không nên sử dụng quá nhiều audio enhancement trong ngày đầu vì có thể làm méo giọng và giảm chất lượng ASR.

Ưu tiên:

1. Chọn microphone tốt.
2. Đặt microphone hợp lý.
3. Noise suppression nhẹ.
4. VAD chính xác.

Thiết bị audio tốt thường cải thiện hệ thống nhiều hơn việc thêm một model denoising phức tạp.

9.3 Voice Activity Detection

Silero VAD là lựa chọn thực dụng vì nhẹ, hỗ trợ xử lý chunk nhỏ và được thiết kế cho speech detection thời gian thực. Tài liệu dự án công bố thời gian xử lý một audio chunk khoảng 30 ms có thể dưới 1 ms trên một CPU thread trong điều kiện của họ.

Tham số ban đầu

```
vad:  
  sample_rate: 16000  
  frame_ms: 32  
  speech_threshold: 0.55  
  min_speech_ms: 180  
  min_silence_ms: 450  
  speech_pad_ms: 180  
  max_turn_seconds: 15
```

Logic hysteresis

Không đóng lượt nói ngay khi VAD báo silence một frame.

Dùng:

- Speech start threshold.
- Speech end threshold.
- Consecutive silence duration.
- Padding trước và sau speech.

Buffer

Duy trì pre-roll khoảng 200–300 ms để tránh cắt mất âm đầu câu.

```
Circular audio buffer  
└─ giữ 300 ms audio gần nhất  
  
Khi speech bắt đầu:  
  lấy cả pre-roll + audio mới
```

9.4 Turn Segmentation

Turn segmentation là phần quan trọng nhất của trải nghiệm.

Nếu segment quá ngắn:

- Dịch rời rạc.
- Thiếu context.
- Nhiều bản dịch nhảy liên tục.
- Người dùng khó đọc.

Nếu segment quá dài:

- Latency cao.
- Người nghe phải chờ.

- ASR có thể dùng nhiều bộ nhớ hơn.
- Câu dịch xuất hiện quá muộn.

Quy tắc đề xuất

Commit một segment khi xảy ra một trong các điều kiện:

```
silence >= 450-700 ms
OR
punctuation boundary + stable transcript
OR
segment duration >= 8-12 seconds
OR
speaker/language change
OR
manual end-turn action
```

Semantic chunking

Có thể dịch incremental theo clause.

Ví dụ:

```
"We propose to deliver the first batch in September,
subject to final contract approval."
```

Không nên commit sau:

```
"We propose to deliver..."
```

Có thể commit sau:

```
"We propose to deliver the first batch in September"
```

sau đó append:

```
"subject to final contract approval."
```

9.5 Speech-to-Text

Lựa chọn đề xuất

Sử dụng `faster-whisper`.

Đây là implementation của Whisper sử dụng CTranslate2. Repository của dự án công bố khả năng nhanh hơn implementation Whisper gốc trong benchmark của họ, đồng thời hỗ trợ quantization để giảm memory và tăng tốc trên một số phần cứng.

Model strategy

Hardware	Model ưu tiên	Fallback
Laptop CPU	small hoặc medium quantized	base
NVIDIA 6–8 GB	medium hoặc large-v3 quantized	small
NVIDIA 12 GB+	large-v3	medium
Apple Silicon	small/medium	base
Edge device yếu	tiny/base	push-to-talk

Cấu hình khởi đầu

```
WhisperModel(  
    model_size_or_path="medium",  
    device="cuda",  
    compute_type="float16"  
)
```

Hoặc GPU memory thấp:

```
WhisperModel(  
    model_size_or_path="medium",  
    device="cuda",  
    compute_type="int8_float16"  
)
```

CPU:

```
WhisperModel(  
    model_size_or_path="small",  
    device="cpu",  
    compute_type="int8"  
)
```

ASR output schema

```
{  
    "utterance_id": "utt-102",  
    "speaker_id": "speaker-a",  
    "language": "vi",  
}
```

```
"language_confidence": 0.96,  
"partial_text": "Chúng tôi dự kiến...",  
"final_text": "Chúng tôi dự kiến giao lô hàng đầu tiên vào tháng Chín.",  
"start_ms": 12400,  
"end_ms": 17150,  
"asr_latency_ms": 610  
}
```

Partial transcript strategy

Không gửi toàn bộ buffer vào ASR mỗi 100 ms.

Khuyến nghị:

- Chạy partial mỗi 500–800 ms.
- Sử dụng rolling audio window.
- Giữ overlap.
- Chỉ hiển thị phần ổn định.
- Chạy final pass khi turn kết thúc.

Stable prefix

Ví dụ ASR trả về:

Lần 1: Chúng tôi sẽ giao
Lần 2: Chúng tôi sẽ giao hàng vào
Lần 3: Chúng tôi sẽ giao hàng vào thứ sáu

Stable prefix:

Chúng tôi sẽ giao

UI hiển thị:

Chúng tôi sẽ giao | hàng vào thứ sáu

Trong đó:

- Phần stable: chữ bình thường.
- Phần unstable: chữ mờ.

10. Language Direction Detection

Có ba hướng.

10.1 Auto-detection

ASR tự nhận diện `vi` hoặc `en`.

Ưu điểm:

- Tự nhiên.
- Không cần thao tác.

Nhược điểm:

- Câu ngắn có thể nhận sai.
- Tên riêng tiếng Anh trong câu tiếng Việt có thể gây nhiễu.
- Code-switching khó.

10.2 Manual seat mode

Gán:

Microphone/seat A → Vietnamese
Microphone/seat B → English

Đây là phương án rất ổn định nếu có hai microphone hoặc hai thiết bị.

10.3 Manual push-to-talk mode

Hai nút:

Speak Vietnamese
Speak English

Đây là fallback đáng tin cậy nhất cho demo.

10.4 Khuyến nghị

Hỗ trợ cả ba:

Default: Auto
Fallback 1: Fixed language
Fallback 2: Push-to-talk

Không nên đặt toàn bộ thành công của demo vào auto-detection.

11. Translation Pipeline

11.1 Input normalization

Trước khi dịch:

- Chuẩn hóa khoảng trắng.
- Khôi phục dấu câu.
- Không tự ý thay đổi con số.
- Không lowercase toàn bộ.
- Bảo vệ tên riêng.
- Bảo vệ mã sản phẩm.
- Bảo vệ email, URL và currency.
- Loại bỏ hallucinated repetition.

Ví dụ:

Input:

Chúng tôi đặt mục tiêu doanh thu 2.5 triệu SGD trong Q4

Protected:

Chúng tôi đặt mục tiêu doanh thu <NUM_1> <CUR_1> trong <TERM_1>

Sau khi dịch:

We are targeting revenue of <NUM_1> <CUR_1> in <TERM_1>

Restore:

We are targeting revenue of SGD 2.5 million in Q4.

11.2 Translation model options

Option 1 — Dedicated translation model

Ví dụ:

- EnViT5.
- NLLB.
- MarianMT.
- SeamlessM4T text-to-text.

EnViT5 được công bố riêng cho dịch Anh-Việt và Việt-Anh, do đó đáng để benchmark cho cặp ngôn ngữ của bài toán.

Ưu điểm:

- Dễ chạy local.
- Output có tính quyết định hơn.
- Chi phí inference thấp hơn LLM lớn.
- Ít nguy cơ thêm thông tin.

Nhược điểm:

- Khả năng hiểu ngữ cảnh kinh doanh có thể hạn chế.
- Khó làm instruction-based correction.
- Cần benchmark kỹ với hội thoại thực tế.

Option 2 — LLM translation

Prompt chặt chẽ:

Translate the following business meeting utterance from Vietnamese to English.

Requirements:

- Preserve meaning, intent, names, numbers, dates and commercial terms.
- Do not summarize.
- Do not explain.
- Do not add information.
- Produce only the translation.
- Use concise professional business language.

Glossary:

- Công ty Cổ phần ABC → ABC Joint Stock Company
- nghiệm thu → acceptance testing
- biên bản ghi nhớ → memorandum of understanding

Text:

{{source_text}}

Ưu điểm:

- Xử lý ngữ cảnh tốt.
- Dịch tự nhiên.
- Dễ dùng glossary.
- Có thể sửa disfluency.
- Dễ điều chỉnh business style.

Nhược điểm:

- Latency.
- Chi phí.
- Phụ thuộc mạng nếu dùng API.
- Có nguy cơ paraphrase hoặc thêm ý.

- Cần timeout và retry.

Option 3 — Hybrid translator

Primary: local translation model
Fallback or re-rank: LLM

Hoặc:

First-pass: low-latency model
Second-pass: correction only when confidence is low

Khuyến nghị hackathon

Nếu mạng ổn định:

Local ASR + LLM translation

Nếu ưu tiên full on-premise:

Local ASR + EnViT5/NLLB benchmark winner

Tốt nhất là có backend abstraction để chuyển đổi bằng config.

12. Business Translation Guardrails

12.1 Không được phép tự thêm ý

Translator system prompt:

Never add commitments, assumptions, explanations or details that are not explicitly present in the source.

12.2 Preserve modality

Phải phân biệt:

Source	Meaning
may	có thể
should	nên

Source	Meaning
must	phải
intend to	dự kiến
commit to	cam kết
consider	xem xét
cannot	không thể
have not approved	chưa phê duyệt

12.3 Preserve negation

Tạo validator kiểm tra:

```
not
cannot
do not
have not
chưa
không
không thể
không đồng ý
```

Nếu source có phủ định mà translation không có tín hiệu phủ định, gắn cờ cảnh báo.

12.4 Preserve entities and numbers

Extract trước translation:

```
{
  "numbers": ["25", "2.5 million", "30%"],
  "dates": ["17 July", "Q4"],
  "currencies": ["SGD"],
  "entities": ["AI Singapore", "NTU"]
}
```

Sau translation, kiểm tra các entity này còn tồn tại không.

Nếu mất:

- Retry translation.
- Dùng prompt mạnh hơn.
- Hiển thị warning.
- Không silent failure.

13. Glossary System

Glossary là tính năng có giá trị sản phẩm rất lớn và tương đối dễ xây.

13.1 Glossary schema

```
{
  "source": "biên bản ghi nhớ",
  "target": "memorandum of understanding",
  "direction": "vi-en",
  "case_sensitive": false,
  "category": "legal",
  "priority": 10
}
```

13.2 Các nhóm glossary

- Tên công ty.
- Tên người.
- Tên sản phẩm.
- Thuật ngữ tài chính.
- Thuật ngữ pháp lý.
- Thuật ngữ kỹ thuật.
- Địa danh.
- Tên phòng ban.
- Từ viết tắt.

13.3 Meeting preparation flow

Trước buổi họp:

1. Nhập tên công ty.
2. Nhập tên người tham gia.
3. Upload danh sách thuật ngữ.
4. Chọn chủ đề:
5. Finance.
6. Logistics.
7. Technology.
8. Legal.
9. Investment.
10. Test các câu mẫu.

Đây là một điểm khác biệt tốt khi pitching sản phẩm.

14. Speaker Handling

14.1 Hackathon recommendation

Không nên bắt buộc full diarization.

Sử dụng một trong ba cách:

Cách 1: Hai microphone

- Mic A cho phía Việt Nam.
- Mic B cho phía Singapore.

Đây là cách ổn định nhất.

Cách 2: Seat assignment

Người dùng chọn phía đang nói.

Cách 3: Basic diarization

Sử dụng speaker embedding hoặc model diarization, nhưng chỉ coi là enhancement.

14.2 Speaker label

Dùng:

Vietnamese Delegate
Singapore Delegate
Moderator

thay vì cố đoán tên cụ thể.

14.3 Overlapping speech

Khi có hai người nói cùng lúc:

- Hiển thị cảnh báo "Overlapping speech detected".
- Không cố tạo một bản dịch tự tin giả.
- Có thể yêu cầu một bên nói lại.
- Lưu audio để replay.

Đây là hành vi product đáng tin cậy hơn việc đưa ra output sai.

15. Noise Robustness

15.1 Hardware first

Ưu tiên:

- USB conference microphone.
- Microphone cardioid.
- Đặt mic gần người nói.
- Tránh loa ngoài hướng vào mic.
- Dừng tai nghe nếu bật TTS.
- Test phòng trước demo.

15.2 Software

Có thể áp dụng:

```
Noise suppression
→ VAD
→ ASR
```

Nhưng luôn benchmark A/B vì denoising quá mạnh có thể làm mất phụ âm hoặc méo tiếng Việt.

15.3 Noise test set

Test với:

- Tiếng điều hòa.
- Tiếng gõ bàn phím.
- Tiếng ghế.
- Tiếng nói nền.
- Nhạc nhẹ.
- Phòng vang.
- Người nói xa mic.
- Accent Việt Nam khác nhau.
- Singaporean English.
- Người nói nhanh.
- Người dùng xen từ tiếng Anh vào câu tiếng Việt.

16. Backend Design

16.1 Khuyến nghị công nghệ

```
Backend: Python + FastAPI
Realtime transport: WebSocket
```


Frontend: React/Vite hoặc Next.js
Local storage: SQLite + JSONL
Model runtime: PyTorch/CTranslate2/ONNX Runtime
Packaging: Docker Compose hoặc single executable script

Nếu đội cần tốc độ phát triển cực nhanh:

Frontend: Gradio
Backend: Python

Nếu ưu tiên cảm giác sản phẩm:

Frontend: React
Backend: FastAPI

16.2 Module structure

```
project/
├── apps/
│   ├── api/
│   │   ├── main.py
│   │   ├── websocket.py
│   │   └── routes/
│   └── web/
│       ├── src/
│       └── public/
├── core/
│   ├── audio/
│   │   ├── capture.py
│   │   ├── resample.py
│   │   ├── vad.py
│   │   └── segmenter.py
│   ├── asr/
│   │   ├── base.py
│   │   ├── faster_whisper.py
│   │   └── mock.py
│   ├── translation/
│   │   ├── base.py
│   │   ├── local_model.py
│   │   ├── llm_api.py
│   │   ├── glossary.py
│   │   └── validator.py
│   └── tts/
```

```
|
|
|   ├── base.py
|   └── local_tts.py
|
|   ├── session/
|   │   ├── manager.py
|   │   ├── state.py
|   │   └── events.py
|   └── observability/
|       ├── metrics.py
|       ├── logging.py
|       └── tracing.py
|
|   ├── config/
|   │   ├── default.yaml
|   │   ├── demo.yaml
|   │   └── offline.yaml
|   └── tests/
|       ├── unit/
|       ├── integration/
|       ├── audio_samples/
|       └── evaluation/
|
|   ├── scripts/
|   │   ├── download_models.py
|   │   ├── benchmark.py
|   │   ├── preflight.py
|   │   └── run_demo.py
|   └── data/
|       ├── glossary/
|       ├── sessions/
|       └── evaluation/
|
|   ├── docker-compose.yml
|   ├── Makefile
|   ├── README.md
|   └── pyproject.toml
```

17. Interface-Based Model Abstraction

Mỗi model backend cần cùng một interface.

17.1 ASR interface

```
from dataclasses import dataclass
from typing import Protocol

@dataclass
class TranscriptionResult:
    text: str
    language: str
    confidence: float | None
    is_final: bool
    start_ms: int
    end_ms: int

class ASRProvider(Protocol):
    async def transcribe(
        self,
        audio: bytes,
        sample_rate: int,
        language_hint: str | None = None,
    ) -> TranscriptionResult:
        ...
```

17.2 Translation interface

```
from dataclasses import dataclass
from typing import Protocol

@dataclass
class TranslationResult:
    source_text: str
    translated_text: str
    source_language: str
    target_language: str
    latency_ms: int
    warnings: list[str]

class TranslationProvider(Protocol):
    async def translate(
        self,
        text: str,
        source_language: str,
        target_language: str,
        glossary: dict[str, str] | None = None,
    ) -> TranslationResult:
        ...
```

```
) -> TranslationResult:  
...
```

17.3 Lợi ích

Có thể đổi bằng config:

```
asr:  
  provider: faster_whisper  
  model: medium  
  
translation:  
  provider: local  
  model: envit5
```

Hoặc:

```
translation:  
  provider: llm_api
```

Không thay đổi orchestration hoặc frontend.

18. Event-Driven Processing

Mỗi utterance có ID cố định.

```
audio.received  
speech.started  
asr.partial  
asr.final  
translation.started  
translation.completed  
translation.failed  
utterance.corrected
```

Ví dụ event:

```
{  
  "event": "translation.completed",  
  "session_id": "meeting-001",  
  "utterance_id": "utt-102",  
  "timestamp": "2026-07-17T10:45:22.412Z",  
  "payload": {  
    "source": "Chúng tôi cần thêm hai tuần.",  
  }  
}
```

```
    "translation": "We need two more weeks.",
    "latency_ms": 483
  }
}
```

Ưu điểm:

- Dễ log.
- Dễ replay.
- Dễ debug.
- Dễ nối thêm meeting summary.
- Dễ tính latency.
- Dễ viết automated tests.

19. Concurrency and Queue Design

Không nên để WebSocket handler trực tiếp chạy model lâu.

Pipeline:

```
WebSocket receiver
→ audio queue
→ VAD worker
→ ASR queue
→ ASR worker
→ translation queue
→ translation worker
→ WebSocket publisher
```

19.1 Queue limits

Phải có bounded queue.

```
queues:
  audio_max_items: 200
  asr_max_items: 10
  translation_max_items: 20
```

Nếu queue đầy:

- Không crash.
- Drop partial jobs trước.
- Không drop final utterance.
- Báo trạng thái "processing delayed".
- Giảm tần suất partial ASR.

19.2 Priority

```
Priority 1: Final ASR
Priority 2: Final translation
Priority 3: Partial ASR
Priority 4: TTS
Priority 5: Summary
```

TTS và summary không được cạnh tranh tài nguyên với chức năng dịch chính.

20. Failure Handling

20.1 Timeouts

```
timeouts:
  partial_asr_ms: 1500
  final_asr_ms: 4000
  translation_ms: 3000
  tts_ms: 5000
```

20.2 Retry

- ASR local: không retry vô hạn.
- API translation: tối đa một retry.
- Retry với exponential backoff nhỏ.
- Không retry nếu input rỗng.
- Không retry một partial đã lỗi thời.

20.3 Circuit breaker

Nếu cloud translator lỗi liên tục:

```
3 failures trong 30 giây
→ mở circuit
→ chuyển sang local translator
→ thử lại cloud sau 60 giây
```

20.4 Stale result protection

Mỗi request có:

```
session_id
utterance_id
revision
```

Nếu một kết quả cũ trả về sau một kết quả mới, frontend bỏ qua.

21. Observability

21.1 Log có cấu trúc

```
{
  "level": "INFO",
  "event": "asr.final",
  "utterance_id": "utt-12",
  "audio_duration_ms": 4520,
  "processing_ms": 680,
  "real_time_factor": 0.15,
  "language": "vi"
}
```

21.2 Metrics

Theo dõi:

```
audio_chunk_lag_ms
vad_turn_duration_ms
asr_partial_latency_ms
asr_final_latency_ms
translation_latency_ms
end_to_end_latency_ms
queue_depth
dropped_partial_count
translation_retry_count
language_detection_errors
session_crash_count
```

21.3 Demo diagnostics panel

Có một trang ẩn:

```
/debug
```

Hiển thị:

- GPU memory.
- CPU.
- Model loaded.
- Queue depth.
- Microphone input.
- Last error.
- Latency p50/p95.
- Network status.
- Current backend.

Không hiển thị trang debug trong giao diện chính.

22. Data Storage and Privacy

22.1 Default privacy mode

Mặc định:

- Không lưu raw audio.
- Lưu transcript chỉ trong phiên.
- Cho phép export thủ công.
- Có nút xóa phiên.
- Hiển thị rõ backend local hay cloud.

22.2 Storage modes

```
privacy:
  mode: ephemeral
  store_audio: false
  store_transcript: false
```

Hoặc:

```
privacy:
  mode: meeting_record
  store_audio: true
  store_transcript: true
  retention_days: 7
```

22.3 UI privacy indicator

 Local processing

hoặc:

☁ Translation uses cloud service

Không nên giấu việc dữ liệu được gửi ra ngoài thiết bị.

23. Testing Strategy

23.1 Unit tests

Test:

- Audio resampling.
- VAD state transitions.
- Segment merging.
- Glossary replacement.
- Number extraction.
- Language routing.
- Timeout logic.
- Retry logic.
- Stale result rejection.
- Event serialization.

23.2 Integration tests

Audio file
→ ASR
→ Translation
→ Final event

Xác nhận:

- Không crash.
- Đúng thứ tự event.
- Không mất utterance.
- Translation không rỗng.
- Latency trong giới hạn.

23.3 Golden test set

Tạo khoảng 50–100 câu business meeting.

Nhóm chủ đề

- Greeting.
- Company introduction.

- Product discussion.
- Pricing.
- Delivery.
- Contract.
- Investment.
- Technical integration.
- Security.
- Next steps.

Câu mẫu

Chúng tôi chưa phê duyệt mức giá này.

We can deliver the first batch by 25 September.

Điều khoản thanh toán đề xuất là 30% trả trước.

This discussion does not constitute a binding commitment.

Chi phí triển khai không bao gồm thuế.

23.4 Critical entity test

Mỗi câu chứa:

- Tên.
- Số.
- Ngày.
- Currency.
- Negative.
- Modal verb.

23.5 Noise test

Tạo các bản audio:

clean
air_conditioner
office_noise
keyboard
background_speech
reverberation

```
low_volume
high_volume
```

23.6 Soak test

Cho hệ thống chạy audio liên tục 30–60 phút.

Quan sát:

- Memory leak.
- GPU memory tăng dần.
- Queue backlog.
- WebSocket disconnect.
- Model crash.
- Transcript duplication.

24. Evaluation Framework

24.1 ASR metrics

- Word Error Rate cho tiếng Anh.
- Character Error Rate cho tiếng Việt.
- Entity accuracy.
- Number accuracy.
- Endpoint latency.
- Real-time factor.

24.2 Translation metrics

Automatic metrics chỉ nên dùng tham khảo.

Quan trọng hơn là human scoring:

Tiêu chí	Điểm
Meaning preserved	1–5
Names preserved	1–5
Numbers preserved	1–5
Business tone	1–5
Fluency	1–5
No added information	1–5

24.3 Product metrics

- Time to first useful output.
 - Số lần người dùng cần thao tác.
 - Số lượt nói bị mất.
 - Số lần transcript nhảy ngược.
 - Số lỗi cần nói lại.
 - Số lỗi hệ thống.
 - Khả năng khôi phục sau lỗi.
-

25. Two-Day Execution Plan

Day 0 — Chuẩn bị trước hackathon

Nếu được phép chuẩn bị môi trường trước:

- Download model.
- Test CUDA.
- Chuẩn bị sample audio.
- Chuẩn bị skeleton FastAPI + React.
- Chuẩn bị interface ASR/translation.
- Chuẩn bị Docker image.
- Chuẩn bị glossary mẫu.
- Chuẩn bị script benchmark.
- Chuẩn bị backup laptop.
- Chuẩn bị USB microphone.
- Cache tất cả model.

Không phụ thuộc việc download model trong ngày demo.

Day 1 — Build the reliable vertical slice

08:00–09:00: Chốt scope và architecture

Chốt:

```
Text-first  
Cascade pipeline  
Local VAD  
Local ASR  
Translation backend abstraction  
Web UI  
No mandatory TTS
```

Giao vai trò:

Người	Trách nhiệm
Engineer 1	Audio, VAD, ASR
Engineer 2	Translation, glossary, validation
Engineer 3	UI, orchestration, deployment

09:00–12:00: End-to-end basic pipeline

Mục tiêu trước buổi trưa:

Microphone
→ ASR final
→ Translation
→ UI

Chưa cần:

- Partial transcript đẹp.
- Speaker diarization.
- TTS.
- Summary.

Chỉ cần hoàn thành happy path.

12:00 milestone

Phải demo nội bộ được:

1. Nói tiếng Việt.
2. Thấy transcript.
3. Thấy tiếng Anh.
4. Nói tiếng Anh.
5. Thấy transcript.
6. Thấy tiếng Việt.

Nếu chưa đạt milestone này, dừng tất cả tính năng khác.

13:00–16:00: Streaming UX

Thêm:

- VAD.
- Partial transcript.
- Final transcript.
- Turn cards.
- Auto-scroll.

- Status states.
- Latency logging.
- Manual language selection.

16:00–18:00: Reliability

Thêm:

- Timeout.
- Error display.
- Retry.
- Bounded queues.
- Push-to-talk fallback.
- Local fallback.
- Session reset.
- Mic selection.

18:00 milestone

Hệ thống phải chạy được ít nhất 20 phút liên tục.

19:00–22:00: Quality pass

- Benchmark ASR model sizes.
- Benchmark translation backends.
- Tune VAD.
- Tune silence threshold.
- Thêm glossary.
- Fix number/entity preservation.
- Test noisy samples.

Cuối Day 1

Freeze architecture.

Không thay framework hoặc viết lại hệ thống sau thời điểm này trừ khi có lỗi nghiêm trọng.

Day 2 — Product hardening and demo preparation

08:00–10:00: Test matrix

Test:

- VI → EN.
- EN → VI.

- Short utterance.
- Long utterance.
- Number.
- Date.
- Name.
- Negation.
- Background noise.
- Fast speaker.
- Silence.
- Overlapping speech.
- Network loss.
- Backend error.

10:00–12:00: UI polish

- Full-screen mode.
- Font lớn.
- Contrast tốt.
- Original và translation rõ.
- Không quá nhiều nút.
- Status dễ hiểu.
- Clear meeting history.
- Privacy badge.
- Latency không nên hiển thị quá kỹ trên main UI.

12:00 milestone

Feature freeze.

Từ đây chỉ:

- Fix bug.
- Tune config.
- Rehearse.
- Chuẩn bị fallback.

13:00–15:00: Rehearsal

Chạy đúng demo script.

Ghi lại:

- Câu nào ASR hay sai.
- Thuật ngữ nào cần glossary.
- Khoảng cách mic.
- Âm lượng.
- Latency.
- Khi nào cần dùng manual mode.

15:00–17:00: Failure rehearsal

Chủ động tạo lỗi:

- Mất mạng.
- Rút microphone.
- Restart backend.
- Translation timeout.
- GPU out-of-memory giả lập.
- Người nói chen nhau.
- Người đổi ngôn ngữ giữa câu.

Xác định quy trình khôi phục.

17:00 trở đi: Lock demo machine

- Tắt Windows Update.
 - Tắt sleep.
 - Cắm nguồn.
 - Tắt notification.
 - Không update dependency.
 - Không đổi model.
 - Không pull code mới không cần thiết.
 - Chạy preflight.
 - Backup source code.
 - Backup environment.
 - Mở sẵn app.
-

26. Team Responsibilities

Engineer 1 — Speech pipeline

Ownership:

- Microphone.
- Audio buffers.
- VAD.
- Turn segmentation.
- ASR.
- Noise testing.
- Latency profiling.

Engineer 2 — Translation quality

Ownership:

- Translation backend.
- Prompt.

- Glossary.
- Entity preservation.
- Number validation.
- Evaluation set.
- Offline model benchmark.

Engineer 3 — Product and platform

Ownership:

- UI.
- WebSocket.
- Session state.
- Error handling.
- Logging.
- Packaging.
- Demo setup.
- Pitch.

Shared responsibility

- Rehearsal.
 - Bug triage.
 - Product decisions.
 - Demo fallback.
-

27. Deployment Profiles

27.1 Demo profile

```
profile: demo

audio:
  sample_rate: 16000

vad:
  provider: silero
  min_silence_ms: 550

asr:
  provider: faster_whisper
  model: medium
  device: cuda
  compute_type: float16

translation:
  provider: llm_api
  timeout_ms: 2500
```

```
    fallback: local

  ui:
    show_partial: true
    show_debug: false

  privacy:
    store_audio: false
```

27.2 Offline profile

```
profile: offline

asr:
  provider: faster_whisper
  model: medium
  device: cuda

translation:
  provider: envit5

privacy:
  mode: local_only
```

27.3 Edge profile

```
profile: edge

asr:
  model: small
  compute_type: int8

translation:
  provider: compact_local

ui:
  show_partial: false

audio:
  push_to_talk_recommended: true
```

28. Packaging and Run Commands

28.1 Simple local run

```
python scripts/preflight.py
python scripts/download_models.py
python -m apps.api.main
```

Frontend:

```
cd apps/web
npm install
npm run dev
```

28.2 One-command demo

```
make demo
```

Makefile:

```
demo:
    python scripts/preflight.py
    python scripts/run_demo.py
```

28.3 Docker Compose

```
docker compose --profile demo up
```

Không nên bắt buộc Docker nếu CUDA passthrough chưa được kiểm thử chắc chắn.

Cần có native run path song song.

29. Preflight Checklist

Script `preflight.py` kiểm tra:

```
[✓] Python version
[✓] CUDA available
[✓] GPU memory
[✓] ASR model exists
```

```
[✓] Translation model/API available
[✓] Microphone detected
[✓] Sample rate supported
[✓] Web port available
[✓] Disk space
[✓] Internet connectivity, if required
[✓] Local fallback loaded
```

Nếu lỗi, in ra hành động cụ thể:

```
ERROR: Translation API unavailable.
ACTION: Run with --profile offline.
```

30. Demo Strategy

30.1 Demo flow

Part 1 — Natural exchange

Người Việt nói:

Chào mừng đoàn AI Singapore. Hôm nay chúng tôi muốn thảo luận về kế hoạch triển khai thử nghiệm trong quý bốn.

Hệ thống hiển thị bản dịch tiếng Anh.

Người Singapore trả lời:

Thank you. Could you clarify the expected timeline and the number of users in the pilot?

Hệ thống hiển thị bản dịch tiếng Việt.

Part 2 — Business detail challenge

Dùng câu chứa:

- Ngày.
- Số.
- Tiền.
- Phủ định.
- Cam kết.

Ví dụ:

Chúng tôi dự kiến triển khai cho 250 người dùng từ ngày 15 tháng 10, nhưng mức giá này chưa được phê duyệt.

Part 3 — Glossary

Dùng tên công ty hoặc thuật ngữ được cấu hình trước.

Part 4 — Noise

Bật một đoạn tiếng ồn nhẹ hoặc để người khác nói nền.

Part 5 — Privacy

Chuyển sang hoặc giới thiệu local mode:

Audio and transcript can remain on the device.

Part 6 — Product story

Cho thấy:

- Transcript history.
- Correction.
- Export.
- Configurable model backend.
- Edge deployment path.

31. Demo Failure Playbook

Microphone không nhận

1. Chọn lại mic.
2. Reload audio input.
3. Chuyển sang mic laptop.
4. Dùng audio sample prerecorded làm minh họa kỹ thuật, nhưng cần nói rõ đây là fallback.

Auto language detection sai

Chuyển sang:

Manual VI
Manual EN

VAD cắt câu

Chuyển sang push-to-talk.

Cloud translation lỗi

Chuyển local backend.

GPU lỗi

- Restart worker.
- Chuyển model nhỏ.
- Chuyển CPU quantized.
- Giảm partial frequency.

TTS gây echo

Tắt TTS ngay. Text translation vẫn là output chính.

32. Risk Register

Rủi ro	Xác suất	Mức ảnh hưởng	Giảm thiểu
ASR sai do ồn	Cao	Cao	Mic tốt, VAD, noise test
Auto language sai	Trung bình	Cao	Manual mode
Latency cao	Trung bình	Cao	Model nhỏ, incremental pipeline
Translation thêm ý	Trung bình	Cao	Prompt chặt, validators
Mất mạng	Trung bình	Cao	Local fallback
GPU OOM	Trung bình	Cao	Quantization, model fallback
Speaker overlap	Cao	Trung bình	UI warning, etiquette
VAD cắt câu	Trung bình	Cao	Pre-roll, silence tuning
Model download lỗi	Thấp nếu chuẩn bị	Cao	Cache trước
Dependency conflict	Trung bình	Cao	Lock file, frozen environment
UI disconnect	Trung bình	Trung bình	Reconnect và session recovery
TTS echo	Cao	Trung bình	TTS off by default
Diarization sai	Cao	Trung bình	Không bắt buộc diarization

Rủi ro	Xác suất	Mức ảnh hưởng	Giảm thiểu
Demo room khác test room	Cao	Cao	Mic test và fallback modes

33. Maintainability Principles

33.1 Configuration over hardcoding

Tất cả model và threshold qua YAML hoặc environment variables.

33.2 Provider interfaces

Không gọi trực tiếp model từ UI hoặc WebSocket.

33.3 Separation of concerns

- Audio module không biết UI.
- ASR module không biết translation provider.
- Translator không quản lý WebSocket.
- Storage không chạy inference.

33.4 Deterministic session state

Một utterance phải có lifecycle rõ:

```
created
→ recording
→ transcribing
→ transcript_final
→ translating
→ completed
```

33.5 Version everything

Log:

```
app_version
asr_model_version
translation_model_version
config_version
glossary_version
```

33.6 Reproducible environment

Dùng:

- `uv.lock`, `poetry.lock` hoặc pinned `requirements.txt`.
 - Fixed model revision.
 - Config snapshot.
 - Pre-downloaded models.
 - One-command startup.
-

34. Product Roadmap After Hackathon

Phase 1 — Hackathon prototype

- One-device meeting translator.
- Two languages.
- Text output.
- Local ASR.
- Hybrid translation.
- Manual fallback.
- Basic glossary.

Phase 2 — Pilot product

- Two-device mode.
- User authentication.
- Meeting profiles.
- Custom glossary.
- Secure storage.
- Admin dashboard.
- Usage metrics.
- Better speaker attribution.
- Transcript editing.
- Export.

Phase 3 — Enterprise deployment

- Full on-premise.
- Role-based access control.
- Encryption.
- Audit logs.
- Data retention policies.
- Model serving.
- Multi-GPU.
- Organization glossary.
- Document context.
- Private cloud.
- Monitoring and SLA.

Phase 4 — Platform

- More language pairs.
- Mobile clients.
- Meeting integrations.
- Domain-specific translation packs.
- API and SDK.
- Edge deployment.
- Lower-resource language adaptation.

35. Extensibility to Other Languages

Không hardcode:

```
if language == "vi":
```

Dùng language registry:

```
languages:
  vi:
    display_name: Vietnamese
    asr_code: vi
    translation_code: vi
    tts_voice: vi-default

  en:
    display_name: English
    asr_code: en
    translation_code: en
    tts_voice: en-default
```

Translation route:

```
source language
→ provider capability check
→ target language
→ glossary
→ translation
```

Điều này giúp mở rộng sang:

- Thai.
- Indonesian.
- Malay.
- Khmer.

- Lao.
- Burmese.

36. Recommended Decision Matrix

Thành phần	Lựa chọn chính	Fallback
UI	React + FastAPI	Gradio
Transport	WebSocket	HTTP chunk upload
VAD	Silero VAD	Push-to-talk
ASR	faster-whisper medium	small/base
Language detection	ASR auto	Manual language
Translation	LLM hoặc benchmark winner	EnViT5/local
Output	Text	Optional TTS
Speaker detection	Seat/manual	Basic diarization
Storage	SQLite/JSONL	In-memory
Deployment	Native run	Docker
Privacy	Local ASR	Full local profile
Noise strategy	Mic + light preprocessing	Push-to-talk

37. Recommended Final Technical Direction

Main demo pipeline

```

USB conference microphone
  ↓
Browser audio capture
  ↓
WebSocket
  ↓
16 kHz mono resampling
  ↓
Silero VAD
  ↓
Turn segmentation with pre-roll
  ↓
faster-whisper medium/large-v3
  ↓
Stable transcript

```

↓
Glossary and entity protection
↓
Translation backend
↓
Number/negation/entity validation
↓
Bilingual React UI

Backup pipeline

Push-to-talk
↓
faster-whisper small
↓
Local EnViT5 or another local translator
↓
Text UI

Experimental bonus pipeline

Audio
↓
SeamlessM4T / SeamlessStreaming
↓
Direct translated text or speech

Seamless nên được trình bày như bằng chứng rằng kiến trúc có thể phát triển theo hướng end-to-end và on-premise, nhưng pipeline cascade vẫn là hệ thống demo chính nếu nó ổn định hơn.

38. Pitch Positioning

Không nên pitch:

“We connected speech recognition to translation.”

Nên pitch:

“We built a privacy-aware, resilient meeting translation product designed for real business conversations.”

Các điểm chính:

1. **Reliable:** Có fallback và error handling.
2. **Responsive:** Streaming partial transcript và semantic turn segmentation.

3. **Accurate:** Business glossary và entity validation.
 4. **Private:** Có local-processing profile.
 5. **Deployable:** Chạy trên laptop và có edge roadmap.
 6. **Extensible:** Model-provider abstraction và language registry.
 7. **Human-centered:** Text-first, correctable, minimally disruptive.
-

39. Questions for Technical Review

AI hoặc reviewer nên đánh giá cụ thể các câu hỏi sau:

1. Cascade pipeline có phải lựa chọn hợp lý nhất trong giới hạn hai ngày không?
 2. Model ASR nào cho tiếng Việt và Singaporean English cho tỷ lệ latency/accuracy tốt nhất trên hardware mục tiêu?
 3. Nên chọn dedicated machine translation model hay LLM translator?
 4. EnViT5, NLLB và SeamlessM4T cần được benchmark như thế nào?
 5. VAD threshold và turn-end logic có phù hợp với hội thoại business không?
 6. Stable-prefix algorithm nên triển khai ở mức token hay text?
 7. Có cách nào giảm translation latency mà không làm câu bị chia quá nhỏ?
 8. Entity và number validator cần hỗ trợ thêm trường hợp nào?
 9. Local fallback có đủ nhanh trên hardware dự kiến không?
 10. Kiến trúc queue hiện tại có nguy cơ backlog hoặc stale result không?
 11. Có nên dùng hai microphone thay vì diarization không?
 12. Tính năng nào nên loại bỏ để giảm rủi ro demo?
 13. Những failure mode nào còn thiếu?
 14. Có vấn đề license hoặc model redistribution nào cần kiểm tra?
 15. Thiết kế hiện tại có đủ rõ để phát triển thành enterprise on-premise product không?
-

40. Final Recommendation

Đội nên tập trung vào một vertical slice cực kỳ ổn định:

Speak
→ See transcript
→ See translation

Sau khi vertical slice này chạy tốt, thứ tự ưu tiên mở rộng là:

1. Reliability
 2. Turn-taking
 3. Latency
 4. Translation accuracy
 5. Glossary
 6. Noise handling
 7. Product UI
 8. Local fallback

- 9. Speaker handling
- 10. Optional TTS

Không nên đảo thứ tự và làm TTS, diarization hoặc meeting summary trước khi pipeline chính chạy ổn định.

Tiêu chí quyết định cuối cùng cho mọi tính năng phải là:

Tính năng này có làm xác suất demo thành công cao hơn, trải nghiệm cuộc họp tốt hơn hoặc đường phát triển thành sản phẩm rõ ràng hơn không?

Nếu câu trả lời là không, tính năng đó không nên nằm trong phiên bản hackathon.